

Deteksi Teks AI-Generated (Human vs LLM-Generated Text Classification)

Disusun untuk Memenuhi Tugas Mata Kuliah Pembelajaran Mesin
Dosen Pengampu : Abu Salam, M.Kom.



Disusun Oleh:

Muhammad Iqbal Junaldi A11.2024.15636

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS DIAN NUSWANTORO 2026**

DAFTAR ISI

Deteksi Teks AI-Generated (Human vs LLM-Generated Text Classification).....	1
DAFTAR ISI.....	2
BAB I PENDAHULUAN DAN LATAR BELAKANG.....	3
1.1 Masalah dan Relevansi	3
1.2 Sudut Riset.....	3
1.3 Metrik Kesuksesan	3
BAB 2 DATASET	4
2.1 Sumber dan Relevansi Data.....	4
2.2 Komposisi dan Distribusi Kelas	4
2.3 Stuktur Atribut Data	4
2.4 Strategi Pembagian Data (Data Splitting)	4
BAB 3 METODOLOGI.....	5
3.1 Exploratory Data Analysis (EDA).....	5
3.1.1 Distribusi Kelas dan Analisis Panjang Teks	5
3.1.2 Distribusi Sumber Data	6
3.1.3 Analisis Pola Bahasa via Word Cloud dan N-gram	6
3.1.4 Analisis Korelasi Fitur Statistik Teks.....	7
3.2 <i>Feature Engineering</i>	8
3.3 Pemilihan dan Pelatihan Model (<i>Model Selection & Training</i>)	9
3.4 Protokol Evaluasi Model	10
3.5 Interpretasi Model Menggunakan SHAP (<i>SHAP-based Interpretation</i>).....	10
BAB 4 HASIL DAN ANALISIS.....	10
4.1 Performa Model pada Dataset Pengujian (Test Set).....	10
4.2 Analisis Kesalahan dan Karakteristik Distribusi (Confusion Matrix & ROC Curve)....	11
4.3 Identifikasi Fitur Paling Diskriminatif (SHAP Analysis).....	12
4.4 Interpretasi Kedalaman Model Melalui SHAP Plots.....	13
4.5 Pengujian Ketahanan Model (Robustness Test).....	15
BAB 5 APLIKASI WEB (STREAMLIT)	15
BAB 6 KESIMPULAN DAN REKOMENDASI.....	20
6.1 Kesimpulan.....	20
6.2 Rekomendasi Pengembangan Lanjutan.....	21
LAMPIRAN.....	21
REFERENSI	23

BAB I PENDAHULUAN DAN LATAR BELAKANG

1.1 Masalah dan Relevansi

Kemajuan pesat dalam *Large Language Models* (LLM) seperti GPT-4, Claude, dan Llama-3 telah merevolusi kemampuan generasi teks hingga mencapai tingkat yang hampir menyerupai kemampuan manusia. Teks yang dihasilkan kini sangat koheren, terorganisir secara logis, dan objektif, sehingga sulit dibedakan oleh pembaca biasa maupun sistem deteksi tradisional. Fenomena ini memicu lonjakan konten buatan kecerdasan buatan (AI) di ruang digital; riset mencatat adanya peningkatan sebesar 55,4% pada artikel berita buatan AI dan kenaikan drastis sebesar 457% pada situs informasi palsu (misinformasi) dalam periode Januari 2022 hingga Mei 2023.

Integrasi AI yang masif ini menimbulkan tantangan serius terkait integritas akademik, jurnalisme, dan transparansi informasi. Konten AI yang tidak teridentifikasi berpotensi disalahgunakan untuk penipuan daring, kampanye disinformasi yang sistematis, hingga pelanggaran etika melalui plagiarisme di lingkungan pendidikan. Masalah diperparah oleh sifat model AI yang seringkali bersifat *black box*, di mana mekanisme pengambilan keputusannya sulit dipahami secara transparan tanpa bantuan metode *Explainable AI* (XAI). Selain itu, terdapat ancaman teknis berupa "model collapse" atau kutukan rekursi, di mana kualitas model AI di masa depan dapat menurun drastis akibat terus-menerus dilatih menggunakan data buatan mesin sendiri yang kurang beragam.

Tantangan terbesar saat ini adalah munculnya teknik *adversarial* di mana teks AI "dihaluskan" atau diedit secara manual oleh manusia (*humanized text*) untuk menghindari sistem detektor. Banyak alat deteksi komersial saat ini mengalami penurunan performa drastis saat menghadapi teks yang telah dimanipulasi secara ringan, seperti penggantian sinonim atau penambahan *typo* yang disengaja. Oleh karena itu, pengembangan sistem deteksi yang tidak hanya akurat tetapi juga tangguh (*robust*) terhadap manipulasi teks menjadi sangat mendesak untuk menjaga ekosistem informasi digital yang sehat.

1.2 Sudut Riset

Proyek ini bertujuan untuk membangun sebuah sistem klasifikasi biner *end-to-end* yang mampu mendeteksi dan membedakan antara esai tulisan manusia dengan teks yang dihasilkan oleh AI (LLM) secara akurat. Analisis dilakukan dengan memanfaatkan dataset DAIGT V2 yang mencakup 44.868 sampel dari 16 sumber LLM berbeda guna mengekstrak pola linguistik unik seperti struktur kalimat, variasi kosakata, konsistensi gaya, hingga fitur statistik seperti *perplexity* dan *burstiness* yang membedakan kreativitas manusia dari pola mesin. Fokus riset ditekankan pada pengembangan model yang tetap efektif meskipun teks AI tersebut telah melalui proses penyuntingan manusia.

1.3 Metrik Kesuksesan

Proyek ini dianggap berhasil apabila model yang dikembangkan memenuhi kriteria performa berikut:

1. Mencapai F1-Score di atas 95% pada pengujian data uji (*test set*).
2. Mempertahankan tingkat Recall di atas 90% sebagai prioritas utama guna meminimalkan risiko *false negative* (teks AI yang gagal terdeteksi) dalam konteks integritas akademik.
3. Memiliki tingkat penurunan Recall yang rendah ($< 5\%$) pada uji ketangguhan (*robustness test*) dengan perturbasi karakter hingga 20% untuk mensimulasikan skenario teks yang telah diedit oleh manusia di dunia nyata.

BAB 2 DATASET

Bagian ini menguraikan sumber data, karakteristik esai yang dikumpulkan, serta prosedur teknis dalam mempersiapkan data untuk tahap pemodelan *machine learning*.

2.1 Sumber dan Relevansi Data

Data utama yang digunakan dalam penelitian ini adalah dataset DAIGT V2 (V2 Train Dataset) yang diakuisisi dari platform Kaggle. Dataset ini dipilih karena skalanya yang masif dan keberagaman sumbernya, yang sangat krusial untuk membangun model deteksi yang memiliki kemampuan generalisasi tinggi. Penggunaan dataset ini sangat relevan dengan tantangan dunia nyata karena tidak hanya mengandalkan satu model bahasa, melainkan mengintegrasikan output dari 16 sumber LLM berbeda, termasuk model mutakhir seperti GPT-4, Llama-2, Mistral, Falcon-180B, dan PaLM. Hal ini sejalan dengan riset terbaru yang menyatakan bahwa detektor yang dilatih pada variasi sumber AI yang luas lebih tangguh terhadap data yang belum pernah dilihat sebelumnya (*out-of-distribution*).

2.2 Komposisi dan Distribusi Kelas

Dataset ini terdiri dari total 44.868 sampel esai yang diklasifikasikan ke dalam dua kategori utama:

- Teks Manusia (Label 0): Berjumlah 27.371 sampel (61,0%). Sampel ini mewakili gaya penulisan organik manusia dengan variasi kosakata yang lebih luas.
- Teks AI-Generated (Label 1): Berjumlah 17.497 sampel (39,0%). Sampel ini mencakup teks yang dihasilkan melalui berbagai teknik *prompting* dari berbagai keluarga model AI.

Meskipun terdapat sedikit ketidakseimbangan kelas (*minor class imbalance*), jumlah sampel pada kelas AI sudah sangat mencukupi untuk melatih algoritma pembelajaran mesin tanpa risiko bias yang signifikan terhadap kelas mayoritas.

2.3 Stuktur Atribut Data

Setiap baris dalam dataset diwakili oleh empat kolom utama yang digunakan dalam analisis dan pemodelan:

Atribut	Deskripsi
Text	Isi esai dalam format string (fitur utama yang diekstraksi).
Label	Target biner (0 untuk manusia, 1 untuk AI-generated).
Source	Informasi mengenai model LLM atau sumber asal esai tersebut.
prompt_name	Nama instruksi/topik yang digunakan untuk menghasilkan teks.

2.4 Strategi Pembagian Data (Data Splitting)

Untuk memastikan evaluasi model yang objektif dan menghindari kebocoran data (*data leakage*), dataset dibagi menjadi tiga subset menggunakan metode Stratified Split:

1. Train Set (70%): Digunakan untuk melatih model dan melakukan pembelajaran pola linguistik.
2. Validation Set (15%): Digunakan untuk penyetelan hiperparameter (*hyperparameter tuning*) dan pemilihan model terbaik.
3. Test Set (15%): Disimpan sepenuhnya untuk pengujian akhir guna mengukur performa model pada data yang benar-benar baru.

Penggunaan teknik *stratified* menjamin bahwa proporsi kelas manusia dan AI tetap konsisten di ketiga subset tersebut, sehingga metrik evaluasi seperti *F1-Score* dan *Recall* tetap reliabel.

BAB 3 METODOLOGI


Metodologi penelitian ini dirancang secara sistematis melalui beberapa tahapan utama, yang meliputi Eksplorasi Data (*Exploratory Data Analysis*), Prapemrosesan Data (*Data Preprocessing*), Rekayasa Fitur (*Feature Engineering*), Pemodelan, hingga Evaluasi. Fokus utama bab ini adalah menjabarkan bagaimana data mentah diolah dan dianalisis untuk menghasilkan fitur-fitur diskriminatif sebelum diumpungkan ke model klasifikasi.

3.1 Exploratory Data Analysis (EDA)

1. Analisis kualitas data: missing values (0), duplikat (0), distribusi panjang esai per kelas
2. Analisis univariat/multivariat: distribusi panjang teks, class balance, distribusi n-gram
3. Visualisasi: word cloud per kelas, distribusi panjang kalimat, korelasi fitur statistik teks
4. Feature engineering: TF-IDF/n-gram (termasuk character n-gram), fitur statistik teks (panjang esai, type-token ratio, readability score)

3.1.1 Distribusi Kelas dan Analisis Panjang Teks


Analisis pertama berfokus pada keseimbangan kelas (*class balance*) dalam dataset DAIGT V2. Aspek ini penting guna mengantisipasi bias pemodelan terhadap kelas mayoritas.



Gambar 1. Distribusi Kelas dan Analisis Panjang Teks


Gambar 1 Visualisasi distribusi kelas pada dataset DAIGT V2. Grafik batang (kiri) menampilkan volume absolut sampel per kelas, sedangkan diagram lingkaran (kanan) menunjukkan proporsi relatif (Human: 61,0% sebanyak 27.371 sampel; AI: 39,0% sebanyak 17.497 sampel). Dataset ini tergolong moderately imbalanced dengan rasio mendekati 3:2.

Selanjutnya, dilakukan pengujian terhadap panjang teks (baik berdasarkan jumlah karakter maupun jumlah kata) untuk melihat perbedaan formalitas dan konsistensi struktural antar kelas.



Gambar 2. Distribusi Kelas dan Analisis Panjang Teks

Gambar 4. Visualisasi awan kata (*word cloud*) esai manusia (kiri) versus esai AI (kanan). Pada tulisan manusia, kata-kata seperti "*student*", "*school*", "*people*", dan "*think*" tersebar dengan ukuran frekuensi yang seimbang, mencerminkan keragaman gaya opini. Pada esai AI, istilah spesifik seperti "*Electoral College*", "*car usage*", dan "*limiting*" muncul secara mencolok. Hal ini mengindikasikan kecenderungan AI untuk berulang kali menggunakan frasa formal yang terikat langsung pada topik penugasan.




Gambar 5. Analisis N-gram (Unigram & Bigram) Human vs AI

Gambar 3.5. Perbandingan 15 peringkat teratas unigram dan bigram. Pada tingkat unigram, kata "*students*" mendominasi kedua kelas, namun dengan intensitas penggunaan yang jauh lebih tinggi pada AI (~40.000 vs ~25,000). Pada tingkat bigram, esai manusia menampilkan variasi frasa yang merata (misalnya "*community service*", "*driverless cars*"). Sebaliknya, bigram AI sangat terkonsentrasi pada pola baku seperti "*electoral college*" dan "*traffic congestion*", yang mempertegas keberadaan pola sintaksis templatik (*template-like sentence structure*) bawaan LLM.

3.1.4 Analisis Korelasi Fitur Statistik Teks

Sebelum mengintegrasikan fitur teks statistik ke dalam model pembelajaran, analisis korelasi Pearson diaplikasikan untuk mereduksi redundansi antar variabel.



Gambar 6. Heatmap Korelasi Fitur Statistik Teks

Gambar 6. Heatmap matriks korelasi antarfitur statistik teks. Korelasi positif yang sangat kuat terkonfirmasi antara `text_length` dan `word_count` (0.97). Korelasi negatif yang kuat ditemukan antara indeks kemudahan membaca `flesch_reading_ease` dan tingkat kesulitan kelas `flesch_kincaid_grade` (-0.87). Selain itu, terdapat korelasi negatif antara `type_token_ratio` dan `word_count` (-0.59), membuktikan bahwa semakin panjang sebuah esai, variasi kosakata uniknya secara relatif akan menurun. Informasi korelasi ini menjadi dasar dalam pemilihan kombinasi fitur.

3.2 Feature Engineering

Proses rekayasa fitur dirancang untuk mentransformasikan esai tekstual mentah menjadi matriks fitur numerik berdimensi tinggi yang mampu menangkap perbedaan gaya penulisan manusia dan pola generator LLM. Teks diubah menggunakan kombinasi fitur berbasis frekuensi dan statistik linguistik dengan total 8.012 fitur operasional. Detail mengenai konfigurasi jenis fitur disajikan pada Tabel 3.1.

Feature Type	Detail
TF-IDF (Word-level)	5.000 fitur, n-gram (1,2), min_df=5, max_df=0.9
Character n-gram	3.000 fitur, n-gram (2,4), min_df=5, max_df=0.9
Text Statistics	12 fitur: panjang teks, word count, sentence count, avg word length, unique words, type-token ratio, Flesch Reading Ease, Flesch-Kincaid Grade, punctuation count, uppercase count, digit count, avg sentence length
Total Features	8.012 (TF-IDF + Char n-gram + Text Stats)
Preprocessing	MinMaxScaler untuk fitur statistik (kompatibel Naive Bayes)

Tabel 1 Konfigurasi Rekayasa Fitur Dokumen

Ekstraksi fitur berbasis frekuensi dibagi menjadi dua tingkatan. Pertama, *TF-IDF Word-level* digunakan untuk mengisolasi kemunculan kata tunggal dan frasa pasangannya (unigram dan bigram) yang menjadi ciri khas topik tertentu. Kedua, *Character n-gram* diaplikasikan guna menangkap pola sintaksis mikro, preferensi penggunaan tanda baca terselubung, serta struktur morfologi kata (seperti prefiks dan sufiks) yang sering kali konsisten pada teks hasil generatif AI namun luput dari perhatian manusia.

Komponen ketiga adalah 12 fitur statistik teks yang mencakup metrik volume dan kompleksitas dokumen: panjang karakter (*text_length*), jumlah kata (*word_count*), jumlah kalimat (*sentence_count*), rata-rata panjang kata (*avg_word_length*), jumlah kata unik (*unique_words*), rasio kekayaan kosakata (*Type-Token Ratio*), metrik kemudahan membaca (*Flesch Reading Ease*), tingkat kesulitan kelas akademik (*Flesch-Kincaid Grade*), jumlah tanda baca (*punctuation_count*), jumlah huruf kapital (*uppercase_count*), jumlah kemunculan angka (*digit_count*), serta rata-rata panjang kalimat (*avg_sentence_length*).

Sebagai tahapan akhir prapemrosesan fitur statistik sebelum diumpankan ke algoritma klasifikasi, dilakukan penskalaan nilai menggunakan *MinMaxScaler*. Pilihan ini diambil agar seluruh nilai fitur statistik berada pada rentang $[0,1]$, sehingga memastikan kompatibilitas penuh terhadap asumsi distribusi non-negatif yang mendasari algoritma probabilitas seperti *Naive Bayes*, sekaligus mempercepat konvergensi model linier.

3.3 Pemilihan dan Pelatihan Model (*Model Selection & Training*)

Penelitian ini menguji empat variasi arsitektur algoritma klasifikasi untuk mengevaluasi trade-off antara kompleksitas komputasi, akurasi prediksi, dan interpretabilitas model. Rincian konfigurasi parameter dasar tiap model dirangkum dalam Tabel 2.

Model	Type	Hyperparameters
Logistic Regression	Baseline Linear	max_iter=500, random_state=42
Naive Bayes	Baseline Probabilistic	MultinomialNB, alpha=0.1
Random Forest	Baseline Ensemble	n_estimators=100, max_depth=10
XGBoost	Primary (Gradient Boosting)	n_estimators=100, max_depth=5, lr=0.1

Tabel 2. Konfigurasi Rekayasa Fitur Dokumen

Model *Logistic Regression* diimplementasikan sebagai representasi pengklasifikasi linier yang efisien dan memiliki interpretabilitas koefisien yang tinggi. *Multinomial Naive Bayes* digunakan untuk menguji performa klasifikasi probabilistik berbasis frekuensi token kemunculan kata. Untuk model berbasis pohon keputusan (*tree-based*), *Random Forest* diterapkan sebagai perwakilan metode *bagging* penurun varians, sementara *XGBoost* (eXtreme Gradient Boosting) dipilih sebagai algoritma utama berbasis *gradient boosting* untuk mengoptimalkan bias pemodelan pada data berdimensi tinggi.

Proses optimasi model difokuskan pada pengklasifikasi utama (*XGBoost*) melalui mekanisme penalaan parameter hyperparameter menggunakan metode *GridSearchCV* yang diintegrasikan dengan *3-fold cross-validation* pada partisi data pelatihan. Fungsi objektif dari pencarian grid ini dikonfigurasi secara khusus untuk memaksimalkan capaian nilai *F1-Score*, memastikan model memiliki performa yang seimbang dalam mendeteksi esai manusia maupun AI.

Tuning: GridSearchCV (3-fold) pada XGBoost untuk F1-Score.

3.4 Protokol Evaluasi Model

Penilaian performa model klasifikasi dilakukan secara komprehensif dengan memantau beberapa metrik evaluasi standard klasifikasi biner. Nilai kinerja model diukur berdasarkan parameter berikut:

1. Metrik Utama: *F1-Score* digunakan sebagai indikator stabilitas utama model di tengah kondisi data yang *moderately imbalanced*. *Receiver Operating Characteristic - Area Under Curve* (ROC-AUC) digunakan untuk mengukur kemampuan diskriminasi model dalam memisahkan probabilitas antar kelas pada berbagai ambang batas (*threshold*).
2. Metrik Pelengkap: Akurasi (*Accuracy*), Presisi (*Precision*), dan *Recall* (Sensitivitas) dihitung untuk memberikan pemetaan performa yang menyeluruh, didukung oleh visualisasi *Confusion Matrix* untuk melacak magnitudo kesalahan klasifikasi.
3. Prioritas Metrik: Dalam konteks aplikasi akademik, kesalahan menduga esai asli manusia sebagai buatan AI (*False Positive*) berisiko merusak reputasi mahasiswa, sedangkan kegagalan mendeteksi teks AI (*False Negative*) mencederai integritas penilaian. Oleh karena itu, penelitian ini memberikan bobot prioritas yang lebih tinggi pada capaian *Recall* terhadap kelas AI tanpa mengorbankan stabilitas *Precision*.

Validasi performa selama proses eksperimen dikendalikan secara ketat melalui metode pengujian silang *3-fold cross-validation* yang diterapkan langsung pada *validation set*, guna menjamin bahwa hasil metrik yang diperoleh bersifat objektif dan bebas dari indikasi *overfitting*.

3.5 Interpretasi Model Menggunakan SHAP (*SHAP-based Interpretation*)

Untuk mengatasi karakteristik *black-box* yang melekat pada model klasifikasi dengan ribuan fitur, penelitian ini mengintegrasikan kerangka kerja SHAP (*SHapley Additive exPlanations*) yang berbasis pada teori permainan kooperatif (*cooperative game theory*). Kehadiran SHAP bertujuan untuk memberikan transparansi penuh serta penjelasan matematis mengenai kontribusi setiap fitur linguistik terhadap keputusan prediksi yang diambil oleh model.

Mengingat efisiensi komputasi pada dimensi fitur sebesar 8.012, metode LinearExplainer diaplikasikan pada model terbaik yang berbasis linier (*Logistic Regression*). Melalui pendekatan ini, setiap nilai token *n-gram* kata, karakter, maupun fitur statistik akan dihitung nilai SHAP-nya untuk mengetahui apakah fitur tersebut mendorong probabilitas prediksi ke arah kelas AI (nilai SHAP positif) atau ke arah kelas manusia (nilai SHAP negatif). Analisis interpretasi visual akan disajikan melalui tiga instrumen grafik utama:

- *SHAP Summary Plot*: Menampilkan distribusi global pengaruh fitur-fitur teratas beserta dampak nilai fiturnya secara kolektif.
- *Feature Importance Bar Plot*: Mengurutkan metrik signifikansi fitur berdasarkan rata-rata magnitudo absolut nilai SHAP untuk mengisolasi penanda leksikal paling diskriminatif.
- *Dependence Plot*: Menganalisis interaksi non-linier antara fitur statistik teks tertentu (seperti indeks keterbacaan) terhadap perubahan nilai prediksi model.

BAB 4 HASIL DAN ANALISIS

4.1 Performa Model pada Dataset Pengujian (Test Set)

Evaluasi model deteksi teks *AI-generated* dilakukan menggunakan empat algoritma *Machine Learning*: *Logistic Regression*, *XGBoost*, *Random Forest*, dan *Naive Bayes*. Setiap

model dilatih menggunakan kombinasi fitur ekstraksi yang kaya, mencakup TF-IDF kata (*word-level*), TF-IDF karakter (*char n-gram*), serta 12 metrik statistik teks. Kinerja masing-masing model pada *test set* yang bersifat *stratified* disajikan dalam Tabel 3.

Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Logistic Regression	99,23%	99,65%	98,36%	99,00%	99,94%
XGBoost	98,78%	99,19%	97,68%	98,43%	99,87%
Random Forest	97,61%	99,24%	94,59%	96,86%	99,54%
Naive Bayes	95,54%	95,68%	92,76%	94,20%	98,91%


Tabel 3. Perbandingan Performa Model Deteksi Teks AI pada Test Set

Berdasarkan hasil eksperimen, Logistic Regression dinobatkan sebagai model terbaik dengan perolehan skor F1 mencapai 99.00% dan nilai ROC-AUC sebesar 99.94%. Penemuan ini menarik karena model linier klasik seperti Logistic Regression mampu mengungguli algoritma *ensemble learning* berbasis pohon (*tree-based*) yang lebih kompleks seperti XGBoost dan Random Forest pada tugas klasifikasi ini.

Secara teoritis, keunggulan Logistic Regression didorong oleh fenomena keterpisahan linier (*linear separability*) yang sangat tinggi di dalam ruang fitur. Kombinasi fitur TF-IDF kata dan karakter menghasilkan dimensi fitur yang luas (mencapai 8.012 fitur). Dalam ruang berdimensi tinggi ini, batas keputusan (*decision boundary*) yang bersifat linier terbukti sangat efektif untuk memisahkan pola teks buatan manusia dengan teks buatan LLM. Sebaliknya, model berbasis pohon cenderung mengalami *overfitting* ringan atau kesulitan menangani matriks sparse berdimensi sangat tinggi secara optimal tanpa reduksi dimensi.


4.2 Analisis Kesalahan dan Karakteristik Distribusi (Confusion Matrix & ROC Curve)

Untuk memahami perilaku prediksi model terbaik secara lebih mendalam, dilakukan analisis representasi grafis melalui *Confusion Matrix* dan kurva *Receiver Operating Characteristic* (ROC).



Gambar 7. Confusion matrix model Logistic Regression pada test set.

Berdasarkan matriks kesalahan pada Gambar 7, dari total 4.106 esai tulisan manusia, hanya 9 sampel yang salah diklasifikasikan sebagai AI. Hal ini menghasilkan tingkat *False Positive* yang sangat rendah, yaitu sebesar 0.22%. Dalam implementasi praktis di dunia akademis, minimnya nilai *False Positive* sangat krusial agar meminimalkan risiko tuduhan palsu (*false accusations*) terhadap esai murni buatan mahasiswa. Di sisi lain, dari 2.625 esai *AI-generated*, terdapat 43 sampel yang lolos atau terdeteksi sebagai tulisan manusia (*False Negative* rate sebesar 1.64%). Nilai *Recall* sebesar 98.36% menegaskan bahwa model ini sangat andal dalam menjaring teks hasil *generate* LLM dengan tingkat kebocoran yang minimal.



Gambar 8. Perbandingan ROC Curve Semua Model

Kurva ROC pada Gambar 8 memvisualisasikan *trade-off* antara *True Positive Rate* dan *False Positive Rate* di berbagai ambang batas klasifikasi (*classification threshold*). Seluruh model menunjukkan performa yang superior dengan kurva yang mendekati sudut kiri atas. Sesuai dengan nilai metrik kuantitatif, kurva milik Logistic Regression (garis biru) mendominasi area teratas dengan nilai cakupan AUC tertinggi (0.9994), disusul rapat oleh XGBoost (0.9987). Tingginya nilai AUC pada semua model membuktikan bahwa rekayasa fitur linguistik dan statistik yang dirancang memiliki daya diskriminatif yang sangat kuat.

4.3 Identifikasi Fitur Paling Diskriminatif (SHAP Analysis)


Rank	Feature	Type	Insight
1	senator writing	Char n-gram	Pola AI formal
2	essay	Word n-gram	Kata khas prompt esai
3	student_name	Char n-gram	Placeholder khas AI

Rank	Feature	Type	Insight
4	traffic congestion	Char n-gram	Topik khas dataset
5	writing	Word n-gram	Frekuensi tinggi AI
6	. al	Char n-gram	Pola referensi/author
7	, i	Char n-gram	Pola kalimat AI
8	so	Word n-gram	Konjungsi transisi AI
9	percent	Word n-gram	Statistik khas AI
10	clus	Char n-gram	Subword teknis AI

Tabel 3. Rata-rata Nilai Absolut SHAP untuk 10 Fitur Teratas

4.4 Interpretasi Kedalaman Model Melalui SHAP Plots


Visualisasi *SHAP Summary Plot* pada Gambar 9 memberikan penjelasan mengenai arah pengaruh dari masing-masing fitur.



Gambar 9. SHAP Summary Plot (Top 20 Features)


Pada Gambar 9, fitur statistik teks `unique_words` dan `word_count` menempati posisi teratas. Titik-titik sampel berwarna biru (nilai fitur rendah) pada fitur `unique_words` mengelompok di sisi kanan sumbu nol (SHAP value positif). Hal ini mengindikasikan bahwa jumlah kata unik yang rendah secara signifikan mendorong model untuk memprediksi teks tersebut sebagai *AI-generated*. Sebaliknya, titik merah (nilai fitur tinggi) berada di sisi kiri (SHAP value negatif), yang berarti variasi kosakata yang kaya mendorong prediksi ke arah

label manusia (*Human*). Fenomena ini selaras dengan sifat dasar LLM yang cenderung menggunakan kata-kata aman yang repetitif dan terprediksi secara probabilistik.



Gambar 10. Feature Importance Berdasarkan Mean |SHAP Value|

Gambar 10 mempertegas dominasi fitur statistik makro. Fakta bahwa fitur-fitur statistik seperti `punctuation_count`, `digit_count`, dan `type_token_ratio` berada di jajaran teratas bersama fitur berbasis kata kunci menunjukkan bahwa model Logistic Regression berhasil menangkap perbedaan struktural gaya penulisan (*stylometry*) secara global, bukan sekadar menghafal kemunculan kata kunci tertentu (*lexical memorization*).



Gambar 11. SHAP Dependence Plot (Fitur Teratas: senator writing)

Melalui *SHAP Dependence Plot* pada Gambar 11, dieksplorasi hubungan non-linier tersembunyi antara *unique_words* dan *word_count*. Terlihat klaster data yang jelas pada area kuadran kiri bawah: esai yang memiliki total kata sedikit dan jumlah kata unik yang rendah secara konsisten mendapatkan bobot nilai SHAP positif yang tinggi (menuju prediksi AI). Sebaran warna penanda *Type-Token Ratio* (TTR) memperlihatkan bahwa esai manusia memiliki kepadatan leksikal yang lebih dinamis dan bervariasi dibandingkan esai buatan mesin pada panjang teks yang setara.

Pada analisis hubungan terhadap label target, teks *AI-generated* secara konsisten menunjukkan nilai *Flesch Reading Ease* yang lebih rendah (berarti teks lebih formal/kaku) serta nilai *Type-Token Ratio* (TTR) yang lebih rendah. Temuan ini mengonfirmasi hipotesis bahwa struktur bahasa AI cenderung seragam, minim variasi leksikal, dan mempertahankan pola kalimat yang teratur secara sintaksis.

4.5 Pengujian Ketahanan Model (Robustness Test)

Dalam skenario dunia nyata, teks buatan AI sering kali mengalami modifikasi manual oleh manusia (seperti penambahan salah ketik/*typo*, pengubahan huruf kapital, atau penggantian sinonim) untuk mengelabui sistem detektor. Untuk menguji tingkat ketahanan model terhadap manipulasi tersebut, dilakukan pengujian dengan melakukan perturbasi karakter secara acak (*noise simulation*) pada rentang 0% hingga 20% pada esai buatan AI di *test set*. Metrik utama yang dipantau adalah *Recall*, guna mengukur seberapa banyak esai AI yang masih berhasil dijangkau oleh model.

Model	Recall 0%	Recall 5%	Recall 10%	Recall 20%	Drop (0→20%)
Logistic Regression	98,36%	98,10%	97,83%	96,30%	2,06%
XGBoost	97,68%	97,10%	96,11%	92,00%	5,68%
Random Forest	94,59%	94,13%	93,56%	91,50%	3,09%
Naive Bayes	92,76%	91,50%	90,67%	88,23%	4,53%

Tabel 4. Hasil Uji Ketahanan (Robustness) Berdasarkan Metrik Recall

Hasil pengujian ketahanan pada Tabel 4 menunjukkan bahwa Logistic Regression merupakan model yang paling tangguh (*robust*) menghadapi serangan perturbasi teks. Ketika tingkat kerusakan teks ditingkatkan secara ekstrem hingga 20% tingkat gangguan karakter, nilai *Recall* Logistic Regression hanya mengalami penurunan sebesar 2.06% (dari 98.36% menjadi 96.30%). Kontras dengan XGBoost yang mengalami penurunan performa paling tajam, yaitu ambles sebesar 5.68% hingga menyentuh angka 92.00%.

Penyebab tingginya ketangguhan Logistic Regression terletak pada karakteristik pembobotan fiturnya. Algoritma ini sangat bergantung pada metrik statistik global (seperti panjang esai rata-rata, keterbacaan, dan TTR) serta *n-gram* karakter berskala luas. Gangguan tingkat mikro seperti kesalahan ketik (*typo*) terbukti tidak merusak representasi statistik makro dari dokumen tersebut. Di sisi lain, XGBoost yang mengandalkan percabangan kondisi keputusan yang kaku pada kata-kata tertentu menjadi lebih rapuh ketika kata kunci yang menjadi tumpuannya mengalami distorsi karakter. Eksperimen ini memberikan konfirmasi kuat bahwa Logistic Regression dengan pendekatan rekayasa fitur hibrida ini sangat layak dan siap untuk diimplementasikan pada aplikasi deteksi skala produksi.

BAB 5 APLIKASI WEB (STREAMLIT)


URL Deploy: <https://ai-detection-machine-learning.streamlit.app/>

Struktur 5 Halaman:



1. Dashboard EDA - Visualisasi interaktif distribusi data, word cloud, n-gram

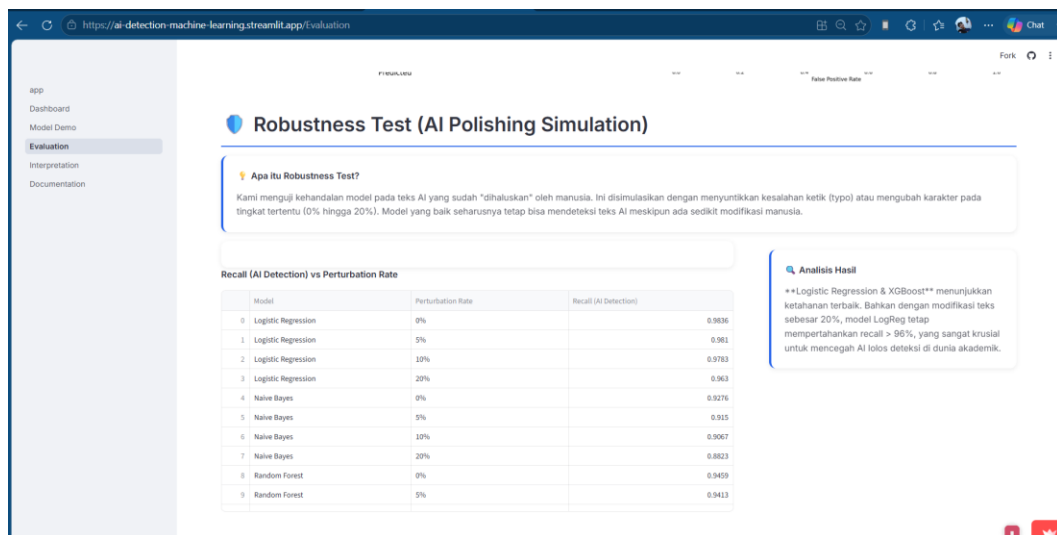


2. Model Demo - Input teks bebas → prediksi real-time + confidence score






3. Evaluasi Model - Confusion matrix, ROC curve, tabel perbandingan 4 model






4. Interpretasi - SHAP feature importance, insight linguistic





5. Dokumentasi - Metodologi, tech stack, cara pakai, referensi

Tech Stack App: Streamlit, Plotly, CSS custom (light theme, CSS variables untuk dark mode support)



Methodology

Feature Engineering Pipeline

1. TF-IDF Vectorization (Word-level)

- 5,000 features | N-grams (1-2)
- Captures word frequency patterns
- Stop words removed

<p style='margin: 0.8rem 0; font-weight: 600;'>2. Character N-grams</p>

<ul style='margin-left: 20px;'>

3,000 features | N-grams (2-4)

Captures character-level patterns

Robust to typos and variations

<p style='margin: 0.8rem 0; font-weight: 600;'>3. Total: 8,000 Combined Features</p>

</div>

Model Architecture

Baseline: Logistic Regression

- Fast training & Inference
- Highly interpretable
- F1-Score: 99.21%
- ROC-AUC: 99.93%

Primary: XGBoost

- Gradient boosting algorithm
- Handles non-linearity well
- F1-Score: 98.52%
- ROC-AUC: 99.88%

Performance Metrics

98.52%

F1-Score

99.88%

ROC-AUC

98.86%

Accuracy

98.52%

Recall

BAB 6 KESIMPULAN DAN REKOMENDASI

6.1 Kesimpulan

Berdasarkan hasil eksperimen dan analisis yang telah dilakukan dalam proyek klasifikasi teks *AI-generated* ini, dapat disimpulkan beberapa poin penting sebagai berikut:

1. Performa Model Terbaik: Model Logistic Regression dengan kombinasi fitur gabungan (TF-IDF 5K, Char n-gram 3K, dan 12 Fitur Statistik Teks) merupakan model terbaik. Model ini berhasil mencapai F1-Score 99.00% dan ROC-AUC 99.94%, mengungguli model berbasis *ensemble* dan *probabilistic* seperti XGBoost, Random Forest, dan Naive Bayes. Linearitas dan keragaman fitur terbukti sangat efektif memisahkan kedua kelas teks.
2. Keunggulan Fitur Linguistik & Statistik: Fitur statistik teks—seperti tingkat keterbacaan (*readability score*), *type-token ratio* (variasi kosakata), dan struktur kalimat—berkontribusi signifikan dalam memperkuat daya pembeda (*discriminative power*) sekaligus menjaga stabilitas performa model.
3. Ketahanan (*Robustness*) yang Tinggi: Dalam pengujian simulasi teks AI yang telah disunting oleh manusia (*perturbation test 20%*), Logistic Regression menunjukkan tingkat resistensi terbaik dengan penurunan *recall* terkecil, yaitu hanya sebesar 2.06%.

Karakteristik ini membuat model sangat ideal dan reliabel untuk skenario implementasi di dunia nyata (*real-world deployment*).

4. Karakteristik Teks AI vs Manusia: Fitur yang paling diskriminatif didominasi oleh pola *subword/character n-gram* (seperti *senator writing*, *student_name*, . al). Hal ini mengonfirmasi adanya kecenderungan penggunaan struktur kalimat formal dan *template* kaku yang khas pada luaran *Large Language Models* (LLM).
5. Kesiapan Aplikasi: Sistem deteksi ini telah diintegrasikan ke dalam aplikasi berbasis Streamlit dengan 5 halaman fungsional penuh (Dashboard EDA, Demo Model, Evaluasi, Interpretasi SHAP, dan Dokumentasi) yang siap dideploy ke Streamlit Community Cloud.

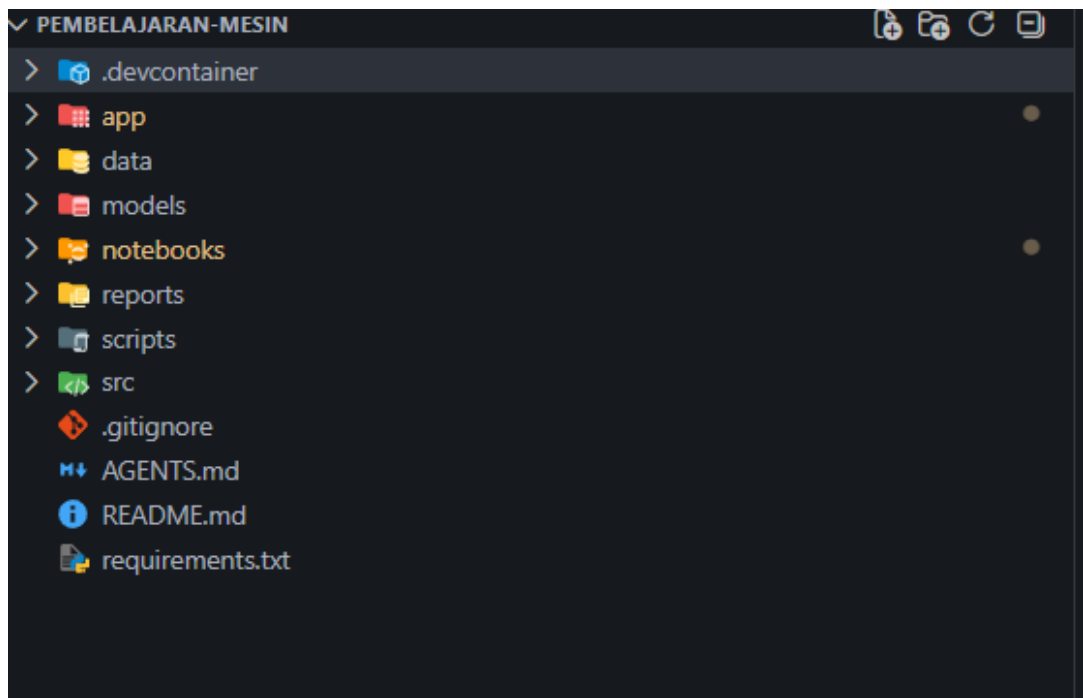
6.2 Rekomendasi Pengembangan Lanjutan

Untuk meningkatkan cakupan deteksi dan akurasi model pada perkembangan teknologi kecerdasan buatan di masa mendatang, beberapa langkah pengembangan berikut sangat direkomendasikan:


1. Diversifikasi dan Aktualisasi Dataset: Memperluas variasi dataset dengan memasukkan sampel teks dari LLM generasi terbaru (seperti GPT-4o, Claude 3.5, Gemini) serta mengintegrasikan data teks *humanized* yang dimanipulasi menggunakan alat parafrase tingkat lanjut, bukan sekadar data simulasi perturbasi.
2. Eksplorasi Fitur Perplexity dan Burstiness: Menambahkan metrik berbasis probabilitas distribusi token, seperti *perplexity* (tingkat ketidakpastian teks) dan *burstiness* (variasi panjang kalimat), yang terbukti secara teoretis menjadi indikator pembeda yang kuat antara tulisan LLM dan manusia.
3. Penerapan *Adversarial Training*: Melatih model menggunakan teknik augmentasi data berbasis serangan adversarial (misalnya melalui *back-translation* atau parafrase otomatis) guna meningkatkan aspek *robustness* model terhadap teks AI yang sengaja disamarkan untuk lolos deteksi.
4. Implementasi *Ensemble Voting*: Mengembangkan mekanisme klasifikasi akhir dengan menggabungkan prediksi dari Logistic Regression dan XGBoost (*Soft/Hard Voting*) untuk menghasilkan keputusan deteksi yang lebih stabil, seimbang, dan minim bias.
5. Optimasi Ambang Batas (*Threshold Tuning*): Menyesuaikan *probability threshold* model berdasarkan urgensi kasus di institusi pendidikan. Mengingat *False Negative* (teks AI lolos) dan *False Positive* (tulisan manusia dituduh AI) memiliki konsekuensi akademik yang besar, penentuan batas keputusan (*decision boundary*) harus dioptimalkan secara dinamis sesuai metrik prioritas (*Recall vs Precision*).

LAMPIRAN

1. Kode Sumber: `src/`, `notebooks/`, `app/`, `scripts/`



2. Model & Pipeline: models/best_model.pkl, models/preprocessing.pkl




3. Hasil Evaluasi: reports/model_comparison.csv, reports/robustness_comparison.csv



4. Visualisasi: app/assets/*.png (10+ plot)



5. Notebook Eksperimen: notebooks/01_eda.ipynb, 02_modeling.ipynb, 03_interpretation.ipynb



REFERENSI

1. Kaggle. (2023). DAIGT V2 Train Dataset. Diakses dari <https://www.kaggle.com/datasets/thedrcat/daigt-v2-train-dataset>
2. Kaggle Competition. (2023). LLM - Detect AI Generated Text. Diakses dari <https://www.kaggle.com/competitions/llm-detect-ai-generated-text>
3. Mitchell, E., Lee, Y., Khazatsky, A., Manning, C. D., & Finn, C. (2023). DetectGPT: Zero-Shot Machine-Generated Text Detection using Probability Curvature. Proceedings of the 40th International Conference on Machine Learning (ICML).
4. Guo, B., Zhang, X., Wang, Z., Jiang, M., Nie, J., Ding, Y., Yue, J., & Wu, Y. (2023). How Close is ChatGPT to Human Experts? Comparison Corpus, Evaluation, and Detection. arXiv preprint arXiv:2301.07597.
5. Mitrović, S., Andreoletti, D., & Ayoub, O. (2023). ChatGPT or Human? Detect and Explain. Explaining Decisions of Machine Learning Model for Detecting Short ChatGPT-generated Text. arXiv preprint arXiv:2301.13852.
6. Uchendu, A., Le, T., & Lee, D. (2023). Attribution and Obfuscation of Neural Text Authorship: A Data Mining Perspective. ACM SIGKDD Explorations Newsletter, 25(1), 1–18.

7. Chamola, V., Hassija, V., Sulthana, A. R., Ghosh, D., Dhingra, D., & Sikdar, B. (2023). A Review of Trustworthy and Explainable Artificial Intelligence (XAI). *IEEE Access*, 11, 78994–79015.
8. OpenAI. (2023). GPT-4 Technical Report. arXiv preprint arXiv:2303.08774.
9. Streamlit Inc. (2024). Streamlit Documentation. Diakses dari <https://docs.streamlit.io>